清华大学硕士学位论文开题报告

面向通用数字智能体的
可扩展评测与训练框架研究

研究生姓名 周博文 学 号 2025213964

院 系 深圳国际研究生院

学 科 电子信息（人工智能）

指 导 教 师 王好谦 专业技术职务 教授

入 学 日 期 2025 年 8 月

2026 年 10 月 22 日

摘　要

通用数字智能体（Universal Digital Agent）以基础模型为核心，旨在真实计算机环境中自主完成长程数字工作，涵盖并拓展了计算机操作智能体（Computer-Use Agent, CUA）。其行动方式可归纳为两类能力：以命令行操作与代码构建为代表的命令行界面（Command-Line Interface, CLI）能力，以及基于屏幕截图感知、以键鼠操作软件的图形用户界面（Graphical User Interface, GUI）能力。二者具有互补性，真实工作要求在同一轨迹中按需交织两类能力，由此提出本课题的核心问题：如何可扩展地测准、练好通用数字智能体，并使其能力在真实世界中可信落地。

现有研究面临三方面挑战。其一，任务范式与能力度量不匹配：纯 GUI 范式开销偏重，主流基准将 CLI 与 GUI 割裂评测，且仅依据最终结果判分。其二，混合行为模式难以习得：图形界面缺少天然的可验证信号，混合训练环境与数据稀缺。其三，通用能力难以落到真实世界：现有个人智能体对用户自有电脑环境与职业业务知识的支持仍不充分，智能体生成的物理仿真程序表象正确并不意味着机制正确。

针对上述挑战，本课题以**可自动构造的验证器（verifier）**为主线，构建“评测—训练—应用”一体化框架，并兼顾 GUI 感知的计算效率。研究一（评测）先提出视觉 token 压缩方法 GUIPruner 与 KV 缓存压缩方法 ST-Lite；进而受 OpenClaw 启发，通过受控实验并结合正反两方面证据，论证 CLI 与 GUI 各有短板、互为补充；据此构建 WeaveBench，以单通道基线与人工审查筛选需 CLI 与 GUI 协同的任务，并以轨迹感知审计实现可信评测，失败归因提示自主编排与自我验证是优先改进方向。研究二（训练）以应用复刻为场景构建可验证环境 RecreationWorld，以原版应用为验证参照（oracle）自动合成隐藏行为测试，作为拒绝采样的可验证筛选信号，获得 3.5 万条轨迹并完成监督微调，Qwen3.7-Plus 与经持续预训练初始化的 Qwen-Flash 在 5 个分布外基准上最高提高 17.9 分。研究三（应用）将框架推广至以财务、电商运营、法律等职业为核心的职业化个人电脑环境，以状态优先的 verifier 构建两阶段训练流程：先以拒绝采样监督微调习得职业任务的行为模式，再以可验证奖励进行强化学习；同时，以反事实干预检验代码智能体所生成的刚体物理仿真程序能否在条件变化下仍遵守物理规律。本课题将为前沿基础模型的能力度量与后训练提供方法、环境与开源基准。

关键词：通用数字智能体；计算机操作；可信评测；可验证环境；强化学习

Abstract

Universal digital agents, which subsume computer-use agents (CUAs), autonomously accomplish long-horizon digital work in real computer environments. Their interaction can be broadly categorized into two complementary capabilities: command-line interface (CLI) interaction (shell and coding), which is precise, efficient and easy to verify but has limited direct access to rendered output; and graphical user interface (GUI) interaction (screenshot perception with mouse and keyboard), which supports a broad range of graphical applications but is costly and lacks readily available verification signals. Real work interleaves both within one trajectory.

This proposal addresses three gaps: task paradigms and capability measurement are mismatched; hybrid behaviors are hard to learn without verifiable environments; and general capabilities are hard to ground in users' own professional environments and in physically correct simulations. Its unifying theme is automatically constructible verifiers, complemented by computational scalability. Study I (evaluation) first reduces GUI perception cost (GUIPruner, ST-Lite), then shows through controlled experiments that CLI and GUI are complementary, and introduces WeaveBench, which combines a task-selection criterion requiring both CLI and GUI with trajectory-aware auditing. Study II (training) proposes RecreationWorld, where a running reference application serves as an oracle for hidden behavioral tests used to filter trajectories by rejection sampling; fine-tuning on 35K trajectories improves performance on five out-of-distribution benchmarks by up to 17.9 absolute points over the first evaluated checkpoint. Study III (application) extends the framework to professional personal-computer environments with state-first verifiers supporting a two-stage pipeline, in which rejection-sampling SFT first instills task-level behavioral patterns and reinforcement learning with verifiable rewards then refines the policy; it further applies counterfactual verification to rigid-body simulation programs written by coding agents.

Keywords: Universal Digital Agent; Computer Use; Trustworthy Evaluation; Verifiable Environment; Reinforcement Learning

目 录

摘 要 I
Abstract II
目 录 III
插图和附表清单 IV
符号和缩略语说明 V
第 1 章 选题背景及意义 1
1.1 研究背景 1
1.2 面临的挑战 2
1.3 选题意义 2
第 2 章 国内外研究现状及分析 3
2.1 纯 CLI 能力方法 3
2.2 纯 GUI 能力方法 3
2.3 混合能力方法与可验证训练环境 4
2.4 面向真实世界的智能体 4
2.5 小结与关键科学问题 5
第 3 章 研究内容与研究方案 6
3.1 总体研究框架 6
3.2 研究一：面向混合能力范式的可信评测 6
3.3 研究二：基于可验证复刻环境的混合行为训练 9
3.4 研究三：面向真实世界的通用数字智能体 11
第 4 章 关键难点、创新点与进度安排 14
4.1 关键难点及拟采取的解决措施 14
4.2 预期创新点 14
4.3 预期成果与学位论文章节安排 15
4.4 论文进度安排 15
4.5 已具备的研究条件、风险与备选方案 15
参考文献 16
个人简历、在学期间发表的学术论文与研究成果 19

插图和附表清单

图 1.1 WeaveBench 运维任务中的混合轨迹示例 1
图 2.1 代表性个人智能体产品 4
图 3.1 可扩展评测与训练框架总览 6
图 3.2 研究一前期工作：编码端视觉 token 剪枝与解码端 KV 缓存压缩 7
图 3.3 纯 GUI、CLI 优先与混合能力三种智能体范式对比..... 8
图 3.4 WeaveBench 的总体设计与失败归因 9
图 3.5 复刻训练在 5 个分布外基准上随训练进程的增益 10
图 3.6 职业化个人智能体及其仿真环境 11
图 3.7 物理仿真程序验证的评测思想与方法框架 13

表 2.1 代码智能体生成物理世界的相关工作 5
表 4.1 论文进度安排 15

符号和缩略语说明

API	应用程序编程接口（Application Programming Interface）
CLI	命令行界面（Command-Line Interface）
CPR	反事实通过率（Counterfactual Pass Rate）
CPT	持续预训练（Continual Pre-Training）
CUA	计算机操作智能体（Computer-Use Agent）
EDA	电子设计自动化（Electronic Design Automation）
ERP	企业资源计划（Enterprise Resource Planning）
FLOPs	浮点运算次数（Floating-Point Operations）
GUI	图形用户界面（Graphical User Interface）
KV	键值（Key-Value），KV 缓存指注意力键值缓存
MCP	模型上下文协议（Model Context Protocol）
OOD	分布外（Out-of-Distribution）
RL	强化学习（Reinforcement Learning）
RQ	研究问题（Research Question）
SFT	监督微调（Supervised Fine-Tuning）
oracle	验证参照，用于判定结果正确性的参考实现
token	词元，模型输入输出的基本单位
verifier	验证器，用于自动判定任务完成情况的程序

第 1 章　选题背景及意义

1.1　研究背景

近年来，以大语言模型与多模态大模型为代表的基础模型在推理、代码与视觉理解能力上取得突破性进展[1]，其应用形态正由“回答问题的对话助手”转向“直接完成工作的智能体”[2]。通用数字智能体（Universal Digital Agent）是其中最具代表性的形态，涵盖并拓展了计算机操作智能体（Computer-Use Agent, CUA）：它以基础模型为决策核心，在真实计算机环境中感知状态、调用工具并执行操作，旨在自主完成软件开发、系统运维、数据分析及各行业业务流程等长程数字工作。GDPval 显示，在其覆盖 44 个职业的任务集上，部分前沿模型的总体交付质量已接近行业专家[3]。

从能力构成看，通用数字智能体的行动方式可归纳为两类能力。其一是 CLI 能力（Command-Line Interface），包括命令行操作（Bash）与代码构建（Coding），代表性工作如 Terminal-Bench[4]、SWE-bench[5] 与 SWE-agent[6]；其二是 GUI 能力（Graphical User Interface），即基于屏幕截图感知界面状态、以鼠标与键盘操作图形界面软件，代表性工作如 OSWorld[7] 与 UI-TARS 系列[8-9]。两类能力具有互补性：前者精确高效、易于验证，但难以直接观测渲染结果；后者适用于广泛的图形界面软件，但开销高、轨迹冗长，且缺少天然的可验证奖励（Verifiable Reward）。

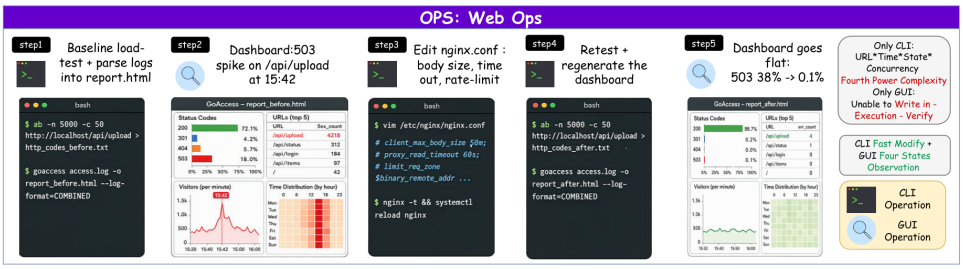


图 1.1　WeaveBench 运维任务中的混合轨迹示例[10]

真实数字工作往往要求在同一条轨迹中交织两类能力。如图 1.1 所示，智能体需要在界面中定位异常、在终端中检索日志并修改配置，再回到界面核验结果，单一能力难以高效完成此类任务[10]。产业上，OpenClaw[11]、Meta Muse[12] 与 OpenAI dots[13] 等个人智能体于 2026 年相继普及或发布。如何可扩展地度量与训练这种混合能力，已成为基础模型研发的重要议题。

1.2 面临的挑战

挑战一：任务范式与能力度量不匹配。纯 GUI 范式每一步都需处理整屏截图，开销随轨迹长度线性增长。WeaveBench 附录 E 的对照实验进一步表明，在以 GUI 为主的 OSWorld 上，同一模型（GPT-5.5、同一判官）仅使用 CLI 与纯 GUI 的成功率点估计接近（79.1% 对 77.3%）[10]，可见纯 GUI 范式并非完成此类任务的唯一途径。与此同时，主流基准将 CLI 与 GUI 割裂评测，任务往往可在单一能力内完成，且多以最终结果判分：在 4 个模型上，仅依据结果的判分比轨迹审计判分高约 10–20 个百分点（如 GPT-5.5 由 53.5% 降至 33.3%）[10]。

挑战二：混合行为模式难以习得。CLI 与 GUI 交织的任务要求智能体具备自主编排（Orchestration）与自我验证（Self-verification）能力。然而，图形界面缺少天然的可验证奖励，现有可验证环境多局限于单一界面[14-15]，而仅依据结果的判分又容易被违规取巧（Reward Hacking）所利用——WeaveBench 的失败归因显示，违规取巧是首要失败类型[10]。

挑战三：通用能力难以落到真实世界。一方面，现有个人智能体的“个人化”多停留于记忆与人设，缺少用户自有的电脑环境与职业业务知识；另一方面，当代码智能体生成物理仿真程序时，结果表象正确并不意味着其遵循物理机制[16-18]，而现有评测难以区分二者。

上述挑战可归结为一个核心问题：**如何可扩展地测准、练好通用数字智能体，并使其能力在真实世界中可信落地？**

1.3 选题意义

围绕这一核心问题，本课题的意义体现在三个层面。**评测层面**，通过受控实验分析 CLI 与 GUI 能力的互补性，经单通道基线与人工审查筛选需两类能力协同的任务，并以面向过程的轨迹审计度量混合能力范式，建立可信的能力度量体系。**方法层面**，以可自动构造的验证器（verifier）贯穿评测与训练：以复刻任务中的原版应用作为验证参照（oracle）提供可扩展的可验证信号，并以反事实干预（Counterfactual Intervention）将“可验证”延伸至物理仿真。**应用层面**，所构建的评测、环境与数据可直接服务于前沿基础模型的后训练。

第 2 章　国内外研究现状及分析

按行动方式，现有通用数字智能体研究可分为纯 CLI 能力方法、纯 GUI 能力方法与混合能力方法三类；与此同时，面向真实世界的个人智能体与物理世界智能体正成为新的研究前沿。本章依次分析各类方法的进展与不足，并据此归纳本课题拟解决的关键问题。

2.1　纯 CLI 能力方法

代码智能体是目前最成熟的数字智能体方向[19]。SWE-bench[5] 以真实 GitHub issue 与单元测试评测仓库级修复；SWE-agent[6] 提出面向语言模型的智能体—计算机接口（Agent-Computer Interface）；SWE-Gym[14] 构建带测试的可执行环境用于训练。命令行智能体将其拓展到一般系统操作：Terminal-Bench[4] 在真实终端中评测编译、配置、数据处理等任务，ServiceNow 的研究表明仅凭终端即可完成大量企业自动化任务[20]。由于单元测试天然提供可验证奖励，该方向率先实现了强化学习的规模化[14,21]。**不足**：其感知局限于可编程接口，难以直接观测渲染结果，在 SWE-bench Multimodal 上最佳系统仅解决约 12% 的任务[22]；对于缺少命令行或 API 的软件则无法覆盖。

2.2　纯 GUI 能力方法

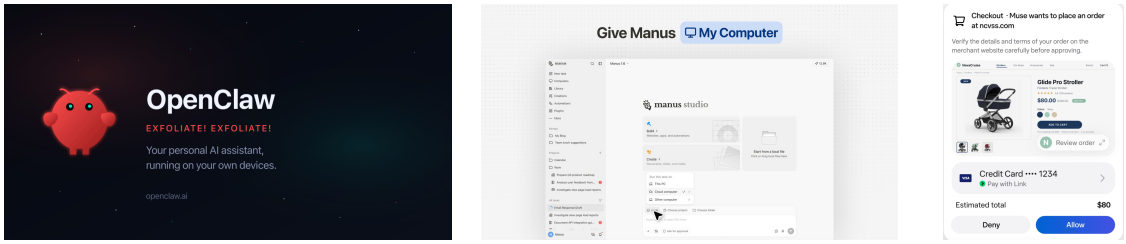
GUI 智能体以截图为输入、以键鼠为动作，适用于广泛的图形界面软件。从界面定位模型 SeeClick[23]、CogAgent[24] 与 OS-ATLAS[25]，到移动端的 Mobile-Agent[26]、AutoGLM[27]，再到端到端的原生智能体 UI-TARS[8] 及引入多轮强化学习的 UI-TARS-2[9]，评测也由网页 WebArena[28]、移动端 AndroidWorld[29] 扩展到桌面 OSWorld[7]；OSWorld[7] 系列基准的公开成绩在约两年内由 12% 左右显著提升至 80% 以上，但版本与设置不一。高效视觉推理方面，FastV[30] 在编码端剪枝视觉 token，SnapKV[31] 在解码端压缩 KV 缓存（KV Cache）。**不足**：截图随步数累积导致开销线性膨胀、轨迹冗长，且难以感知文件、进程等隐藏状态；通用压缩方法未利用 GUI 轨迹的帧间冗余与二维布局；图形界面缺少易于构建的自动验证信号，增加了强化学习规模化的难度。

2.3 混合能力方法与可验证训练环境

为兼取两类能力之长，CoAct-1[32] 令 GUI 操作员与程序员协作，在 OSWorld 上将平均步数由 15 降至 10.15；OSWorld-MCP[33] 在 GUI 之外提供 MCP 工具。对照研究表明，两类能力各有瓶颈：任务与 verifier 一致时，最强 GUI 智能体通过率（59.1%）高于仅使用原生技能的 CLI 智能体（48.2%），补充技能后 CLI 可升至 69.3%[34]。可信评测方面，Agent-as-a-Judge[35] 提出以智能体审计执行过程；训练环境方面，GUI-GENESIS[15] 将真实应用重建为带可验证奖励的环境，Agent World Model[36] 自动合成工具交互环境。**不足**：现有混合基准中第二种能力多为辅助（增益仅约 3–5 个百分点），任务并未强制协同，且仅依据结果判分；可验证训练环境多局限于单一界面，缺少天然要求两类能力交织的训练场景。

2.4 面向真实世界的智能体

个人智能体。2026 年以来，Manus[37] 由云端虚拟机扩展至用户本机，并指出“最重要的工作发生在用户自己的电脑上”；开源的 OpenClaw[11] 运行于用户设备，以 Shell、文件与浏览器为核心工具，截至 2026 年 10 月，其 GitHub 星标数约 39 万；Meta Muse[12] 与 OpenAI dots[13] 则在云端虚拟机中代用户处理购物、订餐与邮件，并持续学习用户偏好（图 2.1）。在职业任务上，GDPval[3] 显示部分前沿模型在 44 个职业上的交付质量已接近行业专家，而在要求于真实工作环境中跨应用执行的 APEX-Agents[38] 上，最佳一次通过率仅为 24.0%，提示真实环境中的长程执行仍具挑战；但由于两者任务集不同，尚不能据此排除业务知识不足的影响。**不足**：现有产品的“个人化”多停留于记忆与人设，执行环境多为厂商云端，对职业专用软件的原生支持不足，且缺少可验证的职业训练环境。



(a) OpenClaw　　(b) Manus　　(c) Meta Muse

图 2.1　代表性个人智能体产品[11-12,37]

物理世界智能体。RobotWorld[18] 在 84 个机器人仿真任务上的最佳成功率仅为 19.0%。2026 年下半年，一批工作开始研究利用代码智能体生成物理仿真场景（表 2.1）。**不足**：这些工作发现可执行并不等同于物理正确（LEGO-Anything 室内场景最佳 53.4%，WorldSolver 最佳总分 48.7%），但大多只在原始条件下检验结果，

跨条件泛化、诊断与回归的联合验证仍不充分。

表 2.1　代码智能体生成物理世界的相关工作

工作	已考察的问题	本文关注的进一步问题
LEGO-Anything[16]	重建静态三维场景	动力学行为的物理一致性
Code4Scene[39]	构建与编辑三维环境	动态行为是否正确
4DCodeBench[40]	复现参考视频中的运动	更换初始条件后是否仍正确
SimWorlds[41]	建立并验证物理机制	参数与跨条件行为
Text2Sim[42]	生成、运行并修复仿真	未见物理条件下的泛化可靠性
WorldSolver[17]	实现物理求解器	复杂场景中自主诊断错误

2.5　小结与关键科学问题

综上，现有研究的不足与第 1 章的三项挑战一一对应，并分别构成本课题三项研究的出发点：（1）**任务范式与能力度量不匹配**——缺少强制 CLI 与 GUI 协同、审计执行过程的统一范式与可信评测，对应研究一（评测）；（2）**混合行为模式难以习得**——缺少天然要求两类能力交织、结果可自动验证的训练环境，对应研究二（训练）；（3）**通用能力难以落到真实世界**——缺少职业化个人环境与物理正确性的可验证手段，对应研究三（应用）。三者共同指向本课题的关键科学问题：**如何可扩展地测准、练好通用数字智能体，并使其能力在真实世界中可信落地？**

第 3 章　研究内容与研究方案

3.1　总体研究框架

针对第 2.5 节归纳的关键科学问题，本课题构建“评测—训练—应用”三段式框架（图 3.1）：研究一（评测）论证并度量混合能力范式；研究二（训练）在可验证环境中训练该范式所要求的行为模式；研究三（应用）将框架推广到职业化个人电脑环境与物理仿真。三者在研究逻辑上递进衔接：研究一的失败归因提示自主编排与自我验证是优先改进方向，构成研究二的动机；研究二在分布外基准上观察到性能提升（复刻数据与 SFT 的净贡献及迁移机制尚待对照实验确认），构成研究三的动机。

贯穿三项研究的主线是**可自动构造的验证器（verifier）**：研究一以轨迹感知判官度量过程，研究二以原版应用为验证参照自动合成隐藏行为测试，研究三以状态优先的 verifier 与反事实干预分别校验职业任务与物理行为。任务、环境与 verifier 可经自动化流水线批量构建并辅以人工审核，此为“可扩展”的第一层含义（构建规模的扩展）；第二层含义是**计算效率的提升**：GUIPruner 与 ST-Lite 降低 GUI 通道的感知开销，使混合智能体的推理与强化学习采样在长程任务上可承受。

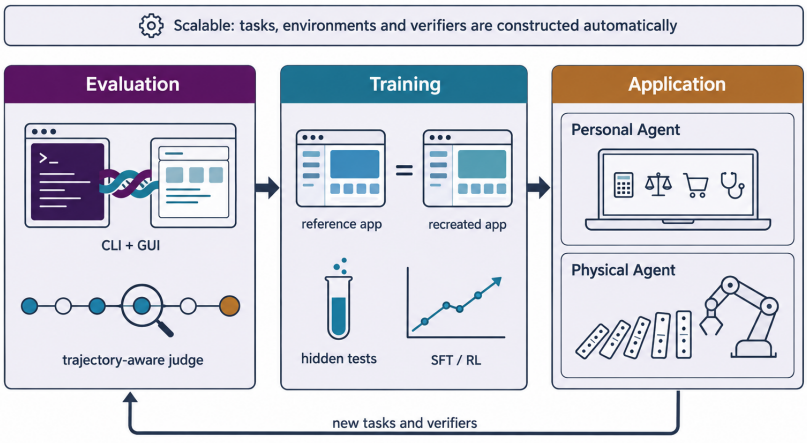


图 3.1　可扩展评测与训练框架总览

3.2　研究一：面向混合能力范式的可信评测

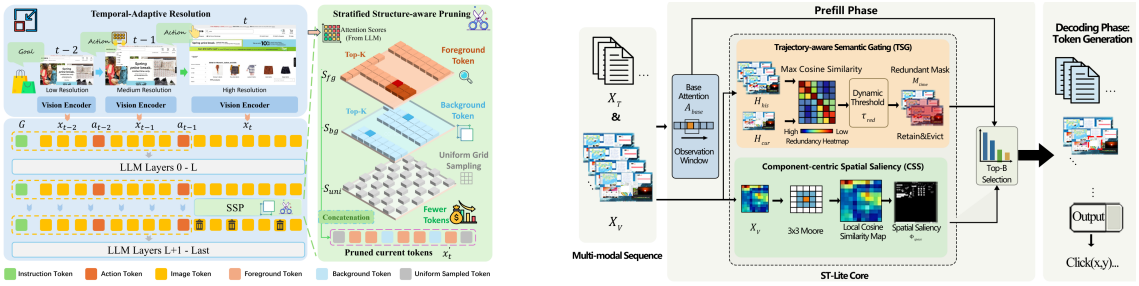
3.2.1　前期探索：纯 GUI 范式下的推理效率优化

长程 GUI 轨迹的每一步都需编码高分辨率截图并累积数十步历史，视觉 token 与 KV 缓存随步数线性膨胀。针对编码端与解码端，本课题分别提出两种无需训

练、即插即用的压缩方法（图 3.2），它们在混合智能体中同样用于降低 GUI 通道的感知开销。

GUIPruner[43] 面向视觉 token 压缩。所考察的压缩方法在 GUI 场景中存在两类不匹配：均匀编码历史帧与智能体“渐隐记忆”式的注意力分布不符（时间不匹配），非结构化剪枝破坏坐标定位所依赖的网格完整性（空间拓扑冲突）。为此，GUIPruner 提出时间自适应分辨率（TAR）与分层结构感知剪枝（SSP），在 Qwen2-VL-2B 上将 FLOPs 降至原来的约 1/3.4、视觉编码速度提升至 3.3 倍，同时保留 94% 以上的性能。

ST-Lite[44] 面向 KV 缓存压缩。GUI 轨迹具有帧间冗余高、界面元素占比小、跨层稀疏度均匀三种性质，致使现有方法在 20% 预算下仅能保留约 39% 的关键键值对。ST-Lite 据此提出轨迹感知语义门控（TSG）与组件中心空间显著性（CSS），在 7 个 GUI 基准上以 20% 预算达到或超过完整缓存的精度，并在 5 倍压缩下取得最高 2.35 倍的解码加速。



(a) GUIPruner：时空 token 剪枝　　(b) ST-Lite：轨迹感知的 KV 缓存压缩

图 3.2　研究一前期工作：编码端视觉 token 剪枝与解码端 KV 缓存压缩[43-44]

3.2.2　范式反思：CLI 与 GUI 互为补充

效率优化能够降低开销，却无法改变纯 GUI 范式逐步处理整屏截图的本质。2026 年初，开源个人智能体 OpenClaw 迅速普及[11]，主要依靠 Shell 命令、代码与程序化浏览器自动化承担日常数字工作。受此启发，本课题将这一观察转化为受控实验（WeaveBench 附录 E[10]）：在 OSWorld 公开排行榜所用的同一环境中，固定模型（GPT-5.5）、指令与判官（经人工审计、参考真值），仅以 OpenClaw CLI 编码智能体（该配置不观察像素）替换纯视觉 GUI 智能体，并同时剔除 8 个需凭据的任务。结果显示，不观察像素的 CLI 智能体成功率为 79.1%，纯视觉智能体为 77.3%，受控设置下两者成功率点估计接近。这表明 OSWorld 中相当比例的任务无需逐帧观察屏幕即可完成，纯 GUI 范式逐步处理整屏截图的开销并非总是必要。

然而，CLI 并不能取代 GUI。反方证据同样明确：CLI 难以直接观测界面，在需要视觉反馈的 SWE-bench Multimodal 上最佳系统仅解决约 12% 的任务[22]；在

任务、初始状态与 verifier 均对齐的受控基准上，最强 GUI 智能体通过率（59.1%）高于仅使用原生技能的 CLI 智能体（48.2%），而补充技能后 CLI 可升至 69.3%[34]，说明 CLI 的表现高度依赖可用工具，二者各有短板、互为补充。上述证据支持在跨接口任务中采用**混合能力范式**；对适合程序化操作的任务，可采用 CLI 主干、GUI 按需观察与核验的策略（图 3.3）；相应地，评测也应度量两类能力的交织，而非孤立地考察其中之一。

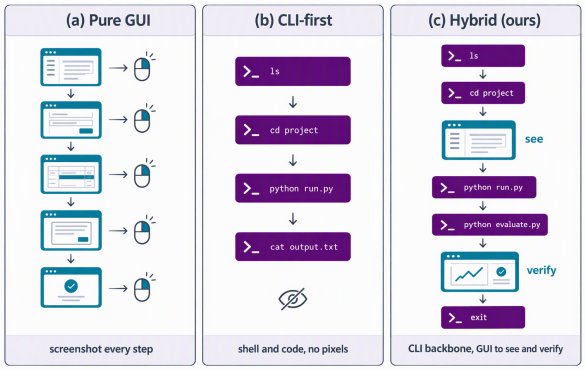


图 3.3　纯 GUI、CLI 优先与混合能力三种智能体范式对比

3.2.3　WeaveBench：混合能力范式下的轨迹感知评测

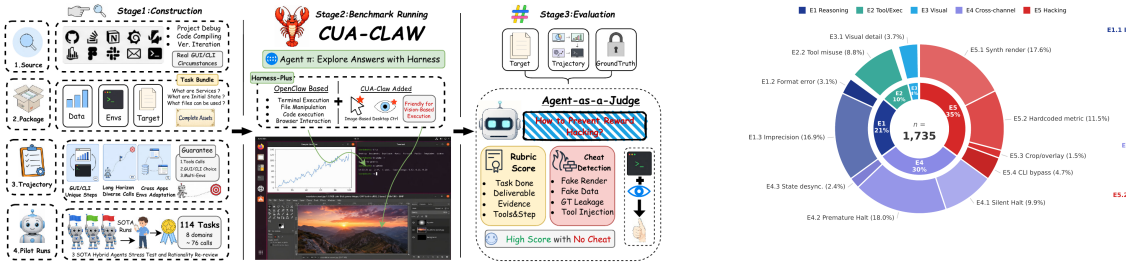
基于上述分析，本课题提出 WeaveBench[10]，以**协同任务筛选**与**轨迹感知审计**为核心，其设计包含三个要点（图 3.4(a)）。

（1）真实运行时。延续上述实验的思路，评测在真实 Ubuntu 桌面上进行，以已部署的 CLI 智能体运行时（以 OpenClaw 为主，并包括 Codex CLI、Claude Code 等）为底座，仅加入提供截图与键鼠接口的轻量桌面控制插件，使智能体在同一循环中兼具两类能力。

（2）面向 CLI 与 GUI 协同的长程任务。WeaveBench 包含 114 个长程任务，覆盖桌面办公、网页开发、数据分析、运维、设计等 8 个真实工作领域；任务来源于用户向已部署的开源智能体运行时提交的真实需求，并具有可公开验证的产物。经单通道基线测试与人工审查，筛选在给定权限与预算下单通道难以完成、协同优势显著的任务。

（3）轨迹感知判官。判官不仅检查最终交付物，还审计文件、截图、日志与动作轨迹，以识别伪造视觉证据、硬编码指标、以 CLI 绕过 GUI 等违规取巧行为。

主要发现。在多种前沿模型与运行时的组合中，最佳组合的通过率仅为 41.2%（同类模型在 OSWorld-Verified 上的成绩超过 78%，仅作背景参考，不同基准不可直接比较）。筛选后任务上的通道消融（用于校验选题设计，而非独立证明）表明，混合通道通过率为 35.1%，而单一通道最高仅 3.5%（差值 31.6 个百分点）；相比之下，在 OSWorld-MCP[33] 等基准中，第二种通道带来的增益仅为数个百分点。在 4



(a) 任务构造与轨迹感知判官　　(b) 1,735 条失败轨迹的归因

图 3.4　WeaveBench 的总体设计与失败归因[10]

个模型上，仅依据结果的判分比轨迹审计判分高约 10–20 个百分点（如 GPT-5.5 由 53.5% 降至 33.3%），表明结果判分在所测设置下高估了智能体能力。对 1,735 条失败轨迹的归因显示，违规取巧（35.2%）与跨通道执行失控（过早停止、状态失同步等，30.4%）合计占 65.6%，而被归为视觉感知错误的失败轨迹占比仅为 3.7%（图 3.4(b)）。

结论与衔接。研究一的失败归因提示，**自主编排与自我验证**（而非视觉感知）是混合能力智能体的优先改进方向；同时，仅依据结果的奖励容易被违规取巧利用。由此引出研究二：如何在结果可验证、且天然要求两类能力交织的环境中训练这一行为模式。

3.3　研究二：基于可验证复刻环境的混合行为训练

3.3.1　训练场景的选择：应用复刻

自主编排与自我验证需要在能力交织、结果可验证的场景中习得。本课题选择应用复刻（App Recreation）作为训练场景：给定一个正在运行的参考应用，智能体需通过界面探索其功能与行为，编写代码实现行为一致的复刻版本，并反复运行、观察与修正，直至复刻版与原版一致。该场景具有三个关键性质：其一，**规格存在于界面中**，智能体必须运用 GUI 能力探索原版应用的交互与状态；其二，**交付物是代码**，必须运用 CLI 能力完成构建与运行；其三，**正确性需运行后经视觉核验**，迫使智能体在两类能力之间反复切换并自我验证。更重要的是，**原版应用本身即为验证参照**：由运行中的参考应用可自动派生隐藏的行为测试，为训练提供客观、基于执行的可验证信号。

3.3.2　可扩展的可验证环境构建

RecreationWorld[45] 在 Ubuntu、macOS、Windows、Android 与 Web 五类平台上提供可复现的环境与统一的智能体框架。环境构建分为四步：选取并固定参考应

用；由智能体探查源码与运行行为，形成行为清单；由平台专用生成器合成程序化断言与视觉断言；在参考应用上回放校验，经人工审核后冻结为隐藏测试集。由于符合筛选条件的开源 GUI 应用经人工审核后，原则上均可经此流程转化为“环境 + 验证参照”，该方法具备可扩展性。据此构建的 RecreationBench 包含 250 个任务（每个平台 50 个）；即便最强模型的测试平均得分（各任务测试通过比例的均值）达到 58.1%，其全测试通过率（通过全部程序化测试的任务占比）也仅为 2.8%，说明复刻任务远未饱和。

3.3.3 训练流程与实验结果

训练流程包括四步。**（1）任务构造**：从 GitHub 上的高质量开源 GUI 应用中采集训练任务，覆盖与 RecreationBench 相同的五类平台，并与评测集去重。**（2）轨迹生成**：使用 Qwen3.8-Max 在隔离的虚拟机池中并发执行“探索—实现—构建运行—核验修正”的复刻循环，并记录完整的交互历史。**（3）可验证筛选**：以隐藏行为测试作为可验证的筛选信号，对轨迹进行拒绝采样（Rejection Sampling），每个平台选取 7,000 条高分轨迹，构成 3.5 万条的均衡训练集。**（4）模型后训练**：以同一份数据分别对完整后训练的 Qwen3.7-Plus 与经持续预训练（Continual Pre-Training, CPT）初始化的 Qwen-Flash 进行监督微调（Supervised Fine-Tuning, SFT）。

如图 3.5 所示（各基准指标不同，图中数值不可横向比较），在覆盖代码、视觉代码与混合计算机操作的 5 个分布外（Out-of-Distribution, OOD）基准上，两种初始化的模型在训练结束时均优于首个已评估检查点，最高提升 17.9 分（OSWorld 2.0 部分得分）。需要说明的是，比较基准是首个已评估检查点而非基座模型，收益来源尚待与训练前模型及等量通用数据的对照实验确认。其中，Qwen3.7-Plus 在研究一提出的 WeaveBench 上的平均部分得分由 35.7 提升至 48.2（与第 3.2.3 节 41.2% 的通过率口径不同，不可直接比较），评测与训练由此初步形成闭环。

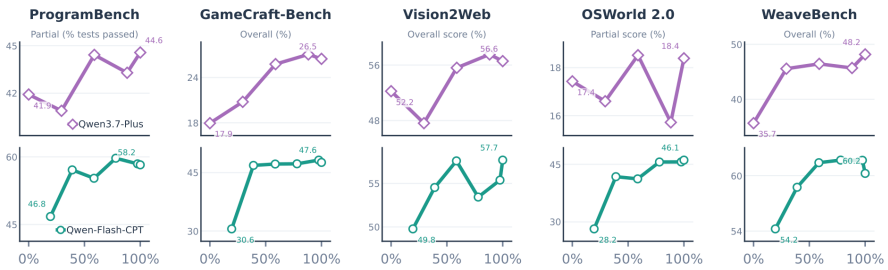


图 3.5 复刻训练在 5 个分布外基准上随训练进程的增益[45]

结论与衔接。研究二表明，以运行中的原版参考应用为验证参照（oracle）的可验证环境能够为混合行为提供可扩展的筛选信号；在所测 5 个分布外基准上观察到提升，复刻数据与 SFT 的净贡献及迁移机制尚待对照实验确认。目前研究二

仅完成拒绝采样监督微调，“先拒绝采样监督微调、后可验证奖励强化学习”的完整两阶段流程将在研究三的职业环境中实施。由此引出研究三：能否将“可验证环境 + 训练流程”推广到更贴近真实需求的职业场景乃至物理仿真。

3.4 研究三：面向真实世界的通用数字智能体

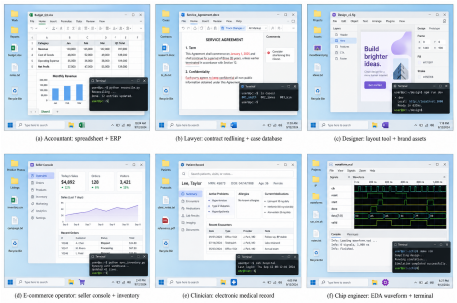
研究三将上述评测与训练框架推广到两类真实世界场景：**职业化个人智能体**与**物理仿真程序的代码智能体验证**。

3.4.1 职业化个人智能体

研究动机。针对第 2.4 节的不足，本课题将同时满足以下三个条件的个人智能体界定为职业化个人智能体（图 3.6(a)）：（1）长期面向**用户自有的电脑环境**；（2）具备相应职业的**业务世界知识**；（3）具备 ERP、合同编辑器、EDA 等专业软件的**使用能力**。本方向的交付物包括职业化个人电脑仿真环境、“先拒绝采样监督微调、后强化学习”的两阶段训练流程，以及小规模真实软件迁移评测。



(a) 职业化个人智能体的三个条件



(b) 多职业个人电脑仿真环境

图 3.6　职业化个人智能体及其仿真环境

研究问题与范围。本方向回答两个问题：RQ1 能否构造可扩展、可验证的职业化个人电脑仿真环境；RQ2 “先拒绝采样监督微调、后强化学习”的两阶段训练能否提升职业任务表现、实现跨职业泛化并迁移到真实软件。研究目标包括职业环境构建、两阶段训练、跨职业评估与小规模真实软件迁移评测；拟以**财务**、**电商运营**、**法律**中的 2–3 个职业为核心职业，另选 1–2 个未参与训练的职业作为留出职业，用于跨职业泛化检验；数据为脱敏或合成业务数据，不接触真实账户。

研究方案。由于职业环境涉及私有系统与业务数据，本课题提出多职业可验证环境扩展（Environment Scaling）流水线：

（1）App Mock：职业化个人电脑环境构建。以研究二的复刻能力为基础，以财务、电商运营、法律中的 2–3 个职业为核心仿真其业务系统（如财务 ERP、卖家后台、合同管理），其余职业留出用于跨职业评估，并与文件系统、邮件、即时

通信等个人应用组合为完整的个人电脑环境（图 3.6(b)）。各仿真应用通过统一状态层关联业务数据，使跨应用操作的结果可被统一观测与校验；智能体无权访问评分数据、隐藏测试与 verifier。

（2）真实数据驱动的环境模拟。以脱敏或合成的业务数据初始化环境状态，并以业务事件（如订单变化、需求变更、客户来信）驱动状态演化；事件依附于智能体的业务动作而非墙钟时间触发，以保证长程、跨应用任务的可复现性。

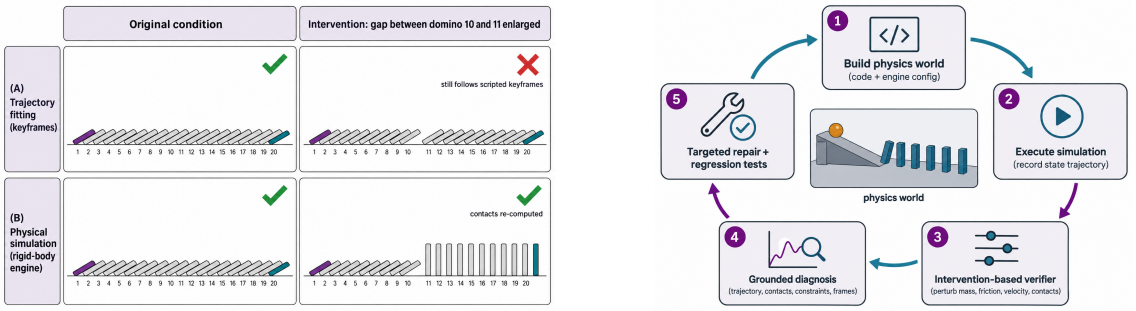
（3）SFT 与 RL 任务构造流水线。由任务生成器在环境中构造职业任务，智能体执行并产生轨迹，**状态优先的 verifier** 以状态与交付物校验判断任务完成度，并结合轨迹审计检查操作合规性；训练分两阶段进行：首先以拒绝采样筛选高分轨迹进行监督微调，使模型习得职业任务的行为模式；随后以该模型为初始策略，将 verifier 分数作为可验证奖励开展强化学习，进一步提升长程任务的成功率与稳健性。评测阶段复用研究一的轨迹感知判官以识别违规取巧行为，研究一的 token 与 KV 缓存压缩方法则用于降低强化学习采样（Rollout）的开销。

评价指标与基线。指标包括状态通过率、过程审计分、跨职业泛化（留出职业上的通过率）与仿真—真实差距（在少量真实软件上的小规模核验）；基线包括通用 CUA 模型、仅 CLI 与仅 GUI 设置，不使用职业数据训练的同规模模型，以及仅完成拒绝采样监督微调阶段的模型（用于检验强化学习阶段的增益）。

3.4.2 面向物理仿真程序的代码智能体验证

问题定义。本方向的研究对象仍是数字智能体：交付物为刚体物理仿真程序的代码智能体。核心问题是其程序是遵循物理机制、可跨条件泛化，还是仅在当前条件下表象正确，以及出错时能否依据执行反馈修复。以多米诺骨牌为例（图 3.7(a)）：方案 A 以关键帧规定每块骨牌的倒下时刻（轨迹拟合），方案 B 设置质量、碰撞体与摩擦并由物理引擎计算运动（物理仿真）。原始条件下二者的渲染视频几乎相同；若将第 10 块与第 11 块骨牌的间距增大至无法接触，方案 A 仍全部倒下，方案 B 则在间隙处正确中断。可见，判断标准应是物理行为能否在不同条件下通过独立验证，而非原始任务的视觉效果。

研究问题。结合表 2.1 的分析，本课题将研究空白界定为：现有评估对**跨条件物理泛化**、**错误的因果定位**与**修复后不破坏既有正确行为**的联合考察仍不充分。据此提出三个研究问题：**RQ1 物理泛化**，生成的仿真能否在未见过的物理条件（质量、摩擦、碰撞参数、初速度与外力）下保持正确；**RQ2 错误诊断**，出错时能否准确区分碰撞体错误、摩擦设置错误与数值积分不稳定等原因，而非随机修改参数；**RQ3 可靠修复**，能否利用物理状态与视觉证据修复仿真并通过回归测试，不破坏原本正确的行为。



(a) 反事实干预检验物理机制　　(b) 验证、诊断与修复流程

图 3.7　物理仿真程序验证的评测思想与方法框架

研究方案。本课题拟提出基于物理状态与干预测试的验证、诊断与定向修复（Physics-Grounded Verification and Targeted Repair）方法，流程如图 3.7(b) 所示：代码智能体构建物理世界并执行仿真、记录状态轨迹；基于干预的 verifier 改变物理参数、初始条件与接触约束，生成反事实测试；结合状态轨迹、接触关系与渲染帧诊断错误原因；最后定向修复，并在原始与全部干预条件下执行回归测试。

设任务的原始条件为 c_0，干预集合为 $\mathcal{C} = \{c_1, \cdots, c_K\}$，智能体生成的世界程序为 W，独立 verifier 在条件 c 下的判定为 $V(W, c) \in \{0, 1\}$。定义反事实通过率

$$\mathrm{CPR}(W) = \frac{1}{K} \sum_{k=1}^{K} V(W, c_k) \tag{3.1}$$

以度量 RQ1；以诊断准确率（智能体定位的错误类型与注入错误一致的比例）度量 RQ2；回归失败率定义为修复前通过、修复后失败的条件占修复前通过条件的比例，用以度量 RQ3 中修复对既有正确行为的破坏；修复成功率定义为修复后在原始条件与全部干预条件下均通过的比例。

实验设计。核心消融在相同的模型、工具权限与计算预算下比较五种反馈设置：One-shot（无反馈）、执行反馈（报错日志）、视觉反馈（渲染图与动画）、物理状态反馈（位置、速度、接触、能量）与本方法（物理状态 + 干预测试 + 诊断与定向修复）。反事实干预与蜕变测试（Metamorphic Testing）[46] 思想一致，以输入变换下输出应满足的关系判定正确性；与评测生成视频物理常识的 PhyGenBench[47] 不同，本方向检验可执行程序的物理机制。

第 4 章　关键难点、创新点与进度安排

4.1　关键难点及拟采取的解决措施

难点一：评测的可信性与可扩展性难以兼顾。解决措施：采用“状态优先、过程审计”的分层判定，优先以数据库状态、文件与产物等可程序化证据判分，对难以程序化验证的过程性要求引入轨迹感知判官并以人工抽检校准；并将违规取巧行为分类纳入判定规则。

难点二：可验证信号的覆盖度与可靠性。解决措施：在多个交互深度上合成程序化与视觉断言，经参考应用回放与人工审核后冻结；训练时结合过程审计抑制针对测试的过拟合。

难点三：职业环境的真实性与隐私约束。解决措施：以复刻能力仿真核心业务流程而非完整软件，以脱敏或合成数据驱动状态演化，通过专家审核控制仿真偏差，并在少量真实软件上进行小规模核验以量化仿真—真实差距。

难点四：训练效果的归因与开销。解决措施：补充训练前模型与等量通用数据两类基线以区分复刻数据的贡献；复用研究一的压缩方法降低推理与采样开销；先以拒绝采样监督微调习得行为模式，再以可验证奖励进行强化学习。

难点五：物理正确性的独立验证。解决措施：以反事实干预生成多组物理条件，结合物理约束与独立参考仿真交叉验证，以状态轨迹为主要判据，并以回归失败率衡量修复的副作用。

4.2　预期创新点

创新点一：混合能力范式下的轨迹感知可信评测。以受控实验与正反两方面证据表明 CLI 与 GUI 具有互补性；以单通道基线测试与人工审查筛选需要两类能力协同完成的任务，并将轨迹感知审计与结果验证相结合；失败归因提示自主编排与自我验证是优先改进方向。

创新点二：以运行中的原版参考应用为验证参照的可扩展复刻训练。以应用复刻为训练场景，使符合筛选条件的开源 GUI 应用可经人工审核转化为“环境 + 隐藏行为测试”，为缺少天然验证信号的图形界面提供可扩展的筛选信号，并在所测分布外基准上观察到提升。

创新点三：面向真实世界的环境扩展与物理落地验证。将可验证环境推广至脱敏或合成数据驱动的职业化个人电脑环境，以状态优先的 verifier 支撑“先拒绝

采样监督微调、后强化学习”的两阶段训练；并以反事实干预检验代码智能体所生成物理仿真程序的机制正确性。

4.3 预期成果与学位论文章节安排

形成“评测—训练—应用”一体化的可扩展框架：构建 2–3 个核心职业的个人电脑可验证环境与 SFT/RL 训练流水线；建立刚体物理仿真的反事实干预评测与诊断、定向修复方法；开源基准、环境与代码。学位论文拟分为 7 章：绪论、相关工作、研究一、研究二、研究三（一）职业化个人智能体、研究三（二）物理仿真程序验证、总结与展望。

4.4 论文进度安排

表 4.1 论文进度安排

时间	工作内容
2025.09 – 2026.09	完成研究一与研究二的主体工作
2026.10 – 2027.01	职业化个人电脑环境构建：核心职业调研、业务系统仿真与统一状态数据库；补充研究二的基线与开源复现
2027.02 – 2027.05	数据驱动与训练流水线：数据驱动状态演化，状态优先的 verifier，拒绝采样 SFT 与可验证奖励 RL，跨职业评估与真实软件迁移评测
2027.06 – 2027.09	物理仿真程序验证：反事实干预基准、诊断与定向修复方法及消融；中期检查
2027.10 起	整合三项研究，补充实验与开源，撰写学位论文并答辩

4.5 已具备的研究条件、风险与备选方案

已具备的条件：研究一、二的评测基准、复刻环境、轨迹数据与训练流程可直接复用于研究三；课题组已具备多卡 GPU 服务器与覆盖五类平台的虚拟机集群；本人在 Qwen 团队实习期间参与 Qwen3.8-Max 研发，研究一、二的环境与数据已用于其模型优化。

风险与备选方案：（1）真实业务数据难以获取时，以合成与公开数据替代；（2）针对强化学习的开销与稳定性，以监督微调模型为初始策略降低探索难度，并按任务长度由短到长设计训练课程；（3）拟在开源模型上检验主要结论的可复现性；（4）物理仿真方向聚焦刚体场景，由小规模基准逐步扩展干预类型与场景规模。

参考文献

[1] 车万翔, 窦志成, 冯岩松, 等. 大模型时代的自然语言处理：挑战、机遇与发展[J/OL]. 中国科学：信息科学, 2023, 53(9): 1645-1687. DOI: 10.1360/SSI-2023-0113.

[2] 陈旭. 基于大语言模型的自主智能体概述[C]//第二十三届中国计算语言学大会论文集（卷 2：前沿综述）. 太原: 中国中文信息学会, 2024: 141-150.

[3] Patwardhan T, Dias R, Proehl E, et al. GDPval: Evaluating AI Model Performance on Real-World Economically Valuable Tasks[EB/OL]. (2025-10-05)[2026-10-17]. https://arxiv.org/abs/2510.04374.

[4] Merrill M A, Shaw A G, Carlini N, et al. Terminal-Bench: Benchmarking Agents on Hard, Realistic Tasks in Command Line Interfaces[C]//International Conference on Learning Representations (ICLR). 2026.

[5] Jimenez C E, Yang J, Wettig A, et al. SWE-bench: Can Language Models Resolve Real-World GitHub Issues?[C]//International Conference on Learning Representations (ICLR). 2024.

[6] Yang J, Jimenez C E, Wettig A, et al. SWE-agent: Agent-Computer Interfaces Enable Automated Software Engineering[C]//Advances in Neural Information Processing Systems (NeurIPS). 2024.

[7] Xie T, Zhang D, Chen J, et al. OSWorld: Benchmarking Multimodal Agents for Open-Ended Tasks in Real Computer Environments[C]//Advances in Neural Information Processing Systems (NeurIPS) Datasets and Benchmarks Track. 2024.

[8] Qin Y, Ye Y, Fang J, et al. UI-TARS: Pioneering Automated GUI Interaction with Native Agents[EB/OL]. (2025-01-21)[2026-10-17]. https://arxiv.org/abs/2501.12326.

[9] Wang H, Zou H, Song H, et al. UI-TARS-2 Technical Report: Advancing GUI Agent with Multi-Turn Reinforcement Learning[EB/OL]. (2025-09-02)[2026-10-17]. https://arxiv.org/abs/2509.02544.

[10] Li W, Zhou B, Yu Y, et al. WeaveBench: A Long-Horizon, Real-World Benchmark for Computer-Use Agents with Hybrid Interfaces[C]//Conference on Empirical Methods in Natural Language Processing (EMNLP). 2026.

[11] OpenClaw Foundation. OpenClaw: Your Personal AI Assistant, Running on Your Own Devices[EB/OL]. (2025-11-24)[2026-10-17]. https://github.com/openclaw/openclaw.

[12] Meta. Introducing Muse: The World's First Personal AI Agent Built for Everyone[EB/OL]. (2026-09-08)[2026-10-17]. https://about.fb.com/news/2026/09/introducing-muse-personal-ai-agent/.

[13] OpenAI. Introducing dots[EB/OL]. (2026-09-29)[2026-10-17]. https://openai.com/index/introducing-dots/.

[14] Pan J, Wang X, Neubig G, et al. Training Software Engineering Agents and Verifiers with SWE-Gym[C]//International Conference on Machine Learning (ICML). 2025.

[15] Cao Y, Ran D, Wu M, et al. GUI-GENESIS: Automated Synthesis of Efficient Environments with Verifiable Rewards for GUI Agent Post-Training[EB/OL]. (2026-02-15)[2026-10-17]. https://arxiv.org/abs/2602.14093.

[16] Li X, Shi P, Dong M, et al. LEGO-Anything: Coding Agents for 3D Scene Reconstruction [EB/OL]. (2026-09-28)[2026-10-17]. https://arxiv.org/abs/2609.36380.

[17] Jiang S, Lyu Y, Lu S, et al. WorldSolver: Can LLM Agents Simulate the Physical Dynamics via Solver Generation?[EB/OL]. (2026-10-06)[2026-10-17]. https://arxiv.org/abs/2610.08720.

[18] Yang Z, Li C, Hu X, et al. RobotWorld: Benchmarking Multimodal Agents for Robot Use Across Diverse Tasks and Embodiments[EB/OL]. (2026-10-07)[2026-10-17]. https://arxiv.org/abs/2610.10409.

[19] 董益宏, 姜雪, 钱家如, 等. 基于大语言模型智能体的代码生成综述[J]. 软件学报, 2026, 37 (8): 3089-3115.

[20] Bechard P, Ayala O M, Chen E, et al. Terminal Agents Suffice for Enterprise Automation [EB/OL]. (2026-03-31)[2026-10-17]. https://arxiv.org/abs/2604.00073.

[21] Wei Y, Duchenne O, Copet J, et al. SWE-RL: Advancing LLM Reasoning via Reinforcement Learning on Open Software Evolution[C]//Advances in Neural Information Processing Systems (NeurIPS). 2025.

[22] Yang J, Jimenez C E, Zhang A L, et al. SWE-bench Multimodal: Do AI Systems Generalize to Visual Software Domains?[EB/OL]. (2024-10-04)[2026-10-17]. https://arxiv.org/abs/2410.03859.

[23] Cheng K, Sun Q, Chu Y, et al. SeeClick: Harnessing GUI Grounding for Advanced Visual GUI Agents[C]//Annual Meeting of the Association for Computational Linguistics (ACL). 2024.

[24] Hong W, Wang W, Lv Q, et al. CogAgent: A Visual Language Model for GUI Agents[C]// IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2024.

[25] Wu Z, Wu Z, Xu F, et al. OS-ATLAS: A Foundation Action Model for Generalist GUI Agents [EB/OL]. (2024-10-30)[2026-10-17]. https://arxiv.org/abs/2410.23218.

[26] Wang J, Xu H, Ye J, et al. Mobile-Agent: Autonomous Multi-Modal Mobile Device Agent with Visual Perception[EB/OL]. (2024-01-29)[2026-10-17]. https://arxiv.org/abs/2401.16158.

[27] Liu X, Qin B, Liang D, et al. AutoGLM: Autonomous Foundation Agents for GUIs[EB/OL]. (2024-10-28)[2026-10-17]. https://arxiv.org/abs/2411.00820.

[28] Zhou S, Xu F F, Zhu H, et al. WebArena: A Realistic Web Environment for Building Autonomous Agents[C]//International Conference on Learning Representations (ICLR). 2024.

[29] Rawles C, Clinckemaillie S, Chang Y, et al. AndroidWorld: A Dynamic Benchmarking Environment for Autonomous Agents[C]//International Conference on Learning Representations (ICLR). 2025.

[30] Chen L, Zhao H, Liu T, et al. An Image is Worth 1/2 Tokens After Layer 2: Plug-and-Play Inference Acceleration for Large Vision-Language Models[C]//European Conference on Computer Vision (ECCV). 2024.

[31] Li Y, Huang Y, Yang B, et al. SnapKV: LLM Knows What You are Looking for Before Generation[C]//Advances in Neural Information Processing Systems (NeurIPS). 2024.

[32] Song L, Dai Y, Prabhu V, et al. CoAct-1: Computer-using Multi-Agent System with Coding Actions[EB/OL]. (2025-08-05)[2026-10-17]. https://arxiv.org/abs/2508.03923.

[33] Jia H, Liao J, Zhang X, et al. OSWorld-MCP: Benchmarking MCP Tool Invocation in Computer-Use Agents[C]//International Conference on Learning Representations (ICLR). 2026.

[34] Zhou X, Zhang S, Zhao Y, et al. GUI vs. CLI: Execution Bottlenecks in Screen-Only and Skill-Mediated Computer-Use Agents[EB/OL]. (2026-06-22)[2026-10-17]. https://arxiv.org/abs/2606.24551.

[35] Zhuge M, Zhao C, Ashley D, et al. Agent-as-a-Judge: Evaluate Agents with Agents[C]// International Conference on Machine Learning (ICML). 2025.

[36] Wang Z, Xu C, Liu B, et al. Agent World Model: Infinity Synthetic Environments for Agentic Reinforcement Learning[C]//International Conference on Machine Learning (ICML). 2026.

[37] Butterfly Effect. Introducing My Computer: When Manus Meets Your Desktop[EB/OL]. (2026-03-16)[2026-10-17]. https://manus.im/blog/manus-my-computer-desktop.

[38] Vidgen B, Mann A, Fennelly A, et al. APEX-Agents[EB/OL]. (2026-01-20)[2026-10-17]. https://arxiv.org/abs/2601.14242.

[39] Ye X, Mantri S H, Chen Z, et al. Code4Scene: Benchmarking Coding Agents for Constructing and Editing 3D Scenes[EB/OL]. (2026-09-29)[2026-10-17]. https://arxiv.org/abs/2609.36777.

[40] Shen R, Kovačič Ž, Kulits P, et al. 4DCodeBench: Benchmarking Agents on Inverse Graphics of Dynamic Scenes[EB/OL]. (2026-10-02)[2026-10-17]. https://arxiv.org/abs/2610.03715.

[41] Liu C, Wang X, Chen H, et al. SimWorlds: A Multi-Agent System for Dynamic 3D Scene Creation[EB/OL]. (2026-07-02)[2026-10-17]. https://arxiv.org/abs/2607.01766.

[42] Xiong X, Wang T H, Qiao Y L, et al. Text2Sim: Agentic Physics-Based Simulation Generation with Distilled Expertise[EB/OL]. (2026-09-29)[2026-10-17]. https://arxiv.org/abs/2609.36593.

[43] Xu Z, Zhou B, Wang Q, et al. Spatio-Temporal Token Pruning for Efficient High-Resolution GUI Agents[EB/OL]. (2026-02-26)[2026-10-17]. https://arxiv.org/abs/2602.23235.

[44] Zhou B, Xu Z, Li W, et al. ST-Lite: Training-Free KV Cache Compression with Spatio-Trajectory Guidance for Long-Horizon GUI Agents[C]//Conference on Empirical Methods in Natural Language Processing (EMNLP). 2026.

[45] Bai S, Deng J, Fan S, et al. RecreationWorld: Scalable and Verifiable Environments for Hybrid Computer-Use Agents[EB/OL]. (2026-09-18)[2026-10-17]. https://arxiv.org/abs/2609.22000.

[46] Chen T Y, Kuo F C, Liu H, et al. Metamorphic Testing: A Review of Challenges and Opportunities[J/OL]. ACM Computing Surveys, 2018, 51(1): 4:1-4:27. DOI: 10.1145/3143561.

[47] Meng F, Liao J, Tan X, et al. Towards World Simulator: Crafting Physical Commonsense-Based Benchmark for Video Generation[EB/OL]. (2024-10-07)[2026-10-17]. https://arxiv.org/abs/2410.05363.

个人简历、在学期间发表的学术论文与研究成果

个人简历

2025 年 8 月进入清华大学深圳国际研究生院，攻读电子信息（人工智能）专业学位硕士至今，导师为王好谦教授。

主要研究方向为通用数字智能体（Universal Digital Agents）与智能体强化学习（Agentic RL）。

发表学术论文

[1] ST-Lite: Training-Free KV Cache Compression with Spatio-Trajectory Guidance for Long-Horizon GUI Agents[C]//Conference on Empirical Methods in Natural Language Processing (EMNLP). 2026. 已录用.

[2] WeaveBench: A Long-Horizon, Real-World Benchmark for Computer-Use Agents with Hybrid Interfaces[C]//Conference on Empirical Methods in Natural Language Processing (EMNLP). 2026. 已录用.

[3] Spatio-Temporal Token Pruning for Efficient High-Resolution GUI Agents[C]//ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD). 2027. 已投稿.

[4] RecreationWorld: Scalable and Verifiable Environments for Hybrid Computer-Use Agents[EB/OL]. (2026-09-18). https://arxiv.org/abs/2609.22000.

专利

无